

AI Gateways: mais segurança e maior governança em suas soluções de Inteligência Artificial!

Renato Groffe

Microsoft MVP, Docker Captain, Grafana Champion, APIsec U Ambassador, MTAC

Carlos Machel

Microsoft MVP, Lead Software Developer



Renato Groffe

- Microsoft Most Valuable Professional (MVP)
- Docker Captain
- Grafana Champion
- APISEC U Ambassador
- Multi-Plataform Technical Audience Contributor (MTAC)
- Arquiteto de Soluções/Software
- +25 anos de experiência na área de Tecnologia
- Community Leader, Autor Técnico e Palestrante



Carlos Machel

- Microsoft Most Valuable Professional (MVP)
- +10 Anos de experiencia na área
- Lead Software Developer na Azure Brasil
- Participo de Lives, faço vídeos regularmente no canal da AzureBrasil no youtube.



Conteúdos desta apresentação



Deixem um star  apoiando

github.com/renatogroffe/ai-gateways_tdc-sp-2026-09



Agenda

- AI Gateways: visão geral, possibilidades e alternativas
- Exemplos práticos



O que é um AI Gateway?

- Ponto central de acesso aos modelos de IA
- Centraliza chamadas para diferentes provedores
- Abstrai detalhes dos modelos e APIs
- Aplica políticas antes das requisições
- Facilita o gerenciamento de aplicações de IA



Por que utilizar um AI Gateway?

- **Governança:** políticas centralizadas para uso de IA
- **Segurança:** controle de acesso, proteção dos endpoints, uso de guardrails sem grandes alterações em aplicações, restringir o acesso a chaves/credenciais e facilitar o rotacionamento...
- **Observabilidade:** métricas, logs e rastreamento
- **Custos:** controle e acompanhamento do consumo
- **Flexibilidade:** troca de modelos sem alterar aplicações, padronização de payloads de request e response...



API Gateways x Segurança

- Autenticação e autorização centralizadas
- Controle de acesso por aplicação ou usuário
- Rate limiting e proteção contra abusos
- Gerenciamento seguro de credenciais
- Filtros/Guardrails para requisições e respostas



Governança e Controle com AI Gateways

- Políticas de uso dos modelos
- Limites de tokens e requisições
- Controle de modelos e provedores permitidos
- Auditoria e rastreabilidade das chamadas
- Acompanhamento de custos (FinOps)



Iniciativas OWASP voltadas à área de IA

- OWASP Top 10 for LLM Applications 2026
- OWASP Top 10 for Agentic Applications for 2026
- OWASP MCP Top 10





AI Gateways: algumas alternativas

- APISIX
- Azure API Management (APIM)
- Azure AI Gateway
- Kong
- LiteLLM
- ...



UNIFIED AI GATEWAY PATTERN





Security



Token Rate Limiting



Prompt Guard



Content Moderation



Logging & Auditing



Prompt Engineering



RAG-Enhanced Prompt



Prompt Decorator



Prompt Template



Observability



Prompt & LLM logs



LLM Latency



Token Usage



Analysis



Reliability



Multi-LLM Load Balancing



LLM Weight and Priority



Retry and Fallback



Caching

LLMs



OpenAI



DeepSeek



Grok



Google Gemini



Claude



Mistral AI



Qwen



Amazon Bedrock



More

Vector Database



PostgreSQL



Redis



Elastic



More

Content Moderation



aws



Azure

Exemplos práticos



Deixem um star 🌟
apoando



Muito obrigado!



Deixem um star 
apoando

